

## Makale Özeti: Gemi Tespiti Uygulamasında YOLOv8 ve YOLOv9 Algoritmalarının Performans Değerlendirmesi

### 1. Giriş

Gemi tespiti, balıkçılık yönetimi, yasadışı göç izleme, deniz kurtarma ve askeri operasyonlar gibi alanlarda kritik bir rol oynamaktadır. Uzaktan algılama teknolojileri, geniş kapsama alanı ve düşük maliyet avantajları nedeniyle bu tür izleme sistemlerinde yaygın olarak kullanılmaktadır. Bu çalışmada, YOLOv8 ve YOLOv9 derin öğrenme modelleri kullanılarak gemi tespiti gerçekleştirilmiş ve iki modelin performansları karşılaştırılmıştır.

### 2. Kullanılan Yöntemler ve Veri Seti

- YOLO Algoritması: YOLO (You Only Look Once) nesne tespitinde yaygın olarak kullanılan, hızlı ve yüksek doğruluk oranına sahip bir modeldir. YOLOv8 ve YOLOv9 modelleri, gelişmiş özellik mühendisliği ve daha iyi nesne tanıma yetenekleri sunmaktadır.
- Veri Seti: Çalışmada "Ships in Google Earth" adlı 1658 görüntüden oluşan bir veri seti kullanılmıştır. Bu veri seti, uydu görüntülerinden elde edilmiş olup farklı hava koşullarını ve gemi tiplerini içermektedir.
- Veri İşleme:
- Görüntüler 640x640 piksel boyutuna getirilmiştir.
- Veri artırma (augmentation) teknikleri uygulanarak eğitim verisi çoğaltılmıştır.
- Gemi tespiti için etiketleme yapılmıştır.
- Model Eğitimi:
- Modeller 25 iterasyon boyunca eğitilmiş, batch\_size değeri 16 olarak belirlenmiştir.
- Modeller, kesinlik (precision), duyarlılık (recall) ve ortalama hassasiyet (mAP) metrikleri ile değerlendirilmiştir.

### 3. Araştırma Bulguları

- YOLOv9 modeli, eğitimin başında daha hızlı yakınsama sağlamış ve erken iterasyonlarda YOLOv8'e göre daha iyi performans göstermiştir.
- mAP değeri açısından YOLOv9, YOLOv8'e kıyasla daha yüksek bir doğruluk oranı yakalamıştır.
- YOLOv9, küçük veya kısmen gizli gemileri tespit etmede daha başarılıdır.
- YOLOv8'in eğitim kaybı eğrileri daha yumuşak olup, daha stabil bir öğrenme süreci sunduğu gözlemlenmiştir.

### 4. Sonuç ve Değerlendirme

- YOLOv9 modeli, genel olarak daha yüksek doğruluk oranı sunmuş ve daha hızlı öğrenme göstermiştir.
- Ancak YOLOv8 daha geniş bir uygulama alanına sahiptir ve stabil eğitim süreci sunmaktadır.
- Seçim, performans gereksinimleri (hız, doğruluk, hesaplama gücü) doğrultusunda belirlenmelidir.
- Gelecekte, farklı tipte deniz araçlarının sınıflandırılması için daha büyük veri setleriyle çalışmalar yapılması planlanmaktadır.

Bu çalışma, YOLO mimarilerinin uzaktan algılama tabanlı gemi tespitinde başarılı bir şekilde kullanılabileceğini göstermektedir.

## **Makale Özeti: Mask R-CNN ile Uydu Görüntülerinde Gemi Tespiti**

### **1. Giriş**

Gemi tespiti, deniz taşımacılığı, güvenlik ve ülke karasularının gözetimi gibi alanlarda önemlidir. Gelişen uydu görüntüleme teknolojileri ve derin öğrenme yöntemleri sayesinde gemi tespiti daha doğru ve hızlı hale gelmiştir. Özellikle **Konvolüsyonel Sinir Ağları (CNN)**, nesne tespiti ve sınıflandırmada yaygın olarak kullanılmaktadır.

### **2. Materyal ve Yöntem**

#### **2.1. Veri Setleri:**

- Çalışmada **Google Earth'ten alınan 1 metre çözünürlüklü 1838 uydu görüntüsü** kullanılmıştır.
- **Toplam 3279 gemi**, GIS yazılımı ile maskelerle etiketlenmiştir.

#### **2.2. Yöntem:**

- Gemi tespiti için **Mask R-CNN modeli** kullanılmıştır.
- Model, **bölge öneri ağı (RPN)** ile nesne konumlarını belirleyerek sınırlayıcı kutular ve maskeler oluşturur.
- **Özellik Piramit Ağı (FPN)** kullanılarak farklı ölçeklerde özellik haritaları oluşturulmuştur.
- Model, **COCO veri setiyle ön eğitilmiş ResNet-101** omurga ağı ile çalıştırılmıştır.

#### **2.3. Model Eğitimi:**

- Model **80 bin iterasyonda** eğitilmiştir.
- Öğrenme oranı **0,001** olarak belirlenmiştir.
- Eğitim **Nvidia GeForce GTX 1080 Ti** ekran kartı ile gerçekleştirilmiştir.

#### **2.4. Tespit Değerlendirme Metrikleri:**

- **Kesinlik (Precision)**, **Geri Getirme (Recall)** ve **F1-Skoru** kullanılarak modelin başarısı ölçülmüştür.

### **3. Bulgular ve Tartışma**

- **Optimal güven eşiği 0,5** olarak belirlenmiştir.
- Model, **604 gemiden 558'ini doğru tespit etmiş**, 46'sını gözden kaçırmış, **58 yanlış alarm** üretmiştir.
- **Geri getirme oranı: 0,9238**
- **Kesinlik: 0,9058**
- **F1-skoru: 0,9148**
- **Zorluklar:**
  - **Birbirine yakın gemileri** bazen tek gemi olarak algılamaktadır.
  - **Karaya yanaşmış bazı gemileri** kaçırmaktadır.
  - **Bazı kara parçalarını yanlışlıkla gemi olarak algılayabilmektedir.**

### **4. Sonuç**

- Mask R-CNN, uydu görüntülerinde **başarılı bir şekilde gemi tespiti yapabilmektedir.**
- Özellikle yakın konumlanmış gemileri tespit etmede modelin iyileştirilmesi gerekmektedir.

- Gelecekte, **diğer nesne tespit modelleri ile karşılaştırma yapılması ve hataların sebeplerinin detaylı analiz edilmesi** planlanmaktadır.

## **Makale Özeti: Derin Öğrenme Yöntemleri ile Şüpheli Davranış Tespiti**

### 1. Giriş

Güvenlik sektöründe bilgi sızıntılarının önlenmesi ve şüpheli davranışların tespiti, hızla gelişen teknolojiyle birlikte önem kazanmıştır. Derin öğrenme yöntemleri, nesne tanıma ve davranış analizi gibi konularda yüksek başarı sağlayarak bu tür güvenlik önlemlerini geliştirmektedir.

### 2. Çalışmanın Amacı

Bu çalışmada, gerçek zamanlı şüpheli davranış tespiti için YOLO (You Only Look Once) algoritması kullanılarak bir sistem geliştirilmiştir. Marmara Üniversitesi Kriminal Davranış/Nesne Veri Seti (MÜKDN) oluşturulmuş ve YOLOv4 modeli ile eğitim gerçekleştirilmiştir.

### 3. Kullanılan Yöntemler

- Veri Seti: 1116 etiketli görsel kullanılarak MÜKDN veri seti oluşturulmuştur.
- Model: YOLOv4 algoritması, yüksek doğruluk ve gerçek zamanlı tespit performansı nedeniyle tercih edilmiştir.
- Veri İşleme:
- Görüntüler belirli bir formatta normalize edilmiş,
- Veri seti %70 eğitim ve %30 test verisi olarak bölünmüş,
- Etiketleme süreci makesense.ai ve LabelBox gibi araçlar ile gerçekleştirilmiştir.

### 4. Sonuçlar ve Değerlendirme

- Model, şüpheli davranış tespiti konusunda %86,13 doğruluk oranı elde etmiştir.
- mAP değeri (ortalama hassasiyet) 0,50 olarak hesaplanmıştır.
- Özellikle cep telefonu veya küçük kamera ile gizli görüntü alma gibi şüpheli eylemleri başarılı bir şekilde tespit edebilmiştir.
- Ancak, bazı özel durumlarda (ellerin gizlenmesi veya bir nesneyle örtülmesi gibi) modelin başarısız olduğu gözlemlenmiştir.

### 5. Gelecek Çalışmalar ve Öneriler

- Daha büyük veri setleri ile modelin doğruluk oranı artırılabilir.
- Model, hırsızlık, şiddet gibi farklı şüpheli davranış türlerini de içerecek şekilde genişletilebilir.
- YOLOv4 modelinde optimizasyon ve farklı hiperparametre ayarlamaları yapılarak başarı oranı artırılabilir.

### 6. Sonuç

Bu alıřma, derin ğrenme tabanlı nesne tespit algoritmalarının řüpheli davranıř tespiti iin kullanılabilirliėini gstermektedir. YOLO algoritmasının hızlı ve yksek doėruluk oranına sahip olması, gvenlik sistemlerinde etkin bir řekilde kullanılabileceėini kanıtlamaktadır.